

Proposta de Projeto Final

Crhisângela Ferreira

CCM-109 — Tópicos Especiais em Inteligência Artificial

Pós-Graduação em Ciência da Computação — UFABC

1. Problema

A predição de propriedades ópticas de moléculas orgânicas é um desafio central em quimioinformática e no desenvolvimento de novos materiais. Em particular, o comprimento de onda de máxima absorção (λ_{max}) no espectro UV-Vis determina aplicações em corantes, sensores e fotocatalisadores. Métodos quânticos como DFT permitem calcular λ_{max} com boa precisão, mas têm custo computacional elevado, inviabilizando triagens em larga escala sobre espaços moleculares amplos.

Este projeto propõe treinar um modelo de aprendizado profundo para prever λ_{max} a partir da representação SMILES de moléculas orgânicas (Etapa 1) e, em seguida, aplicar o modelo treinado como ferramenta de triagem sobre um conjunto proprietário de 5.974 moléculas geradas computacionalmente pelo aluno de iniciação científica do laboratório ABC Sim da UFABC (Etapa 2).

O problema central é formulado como regressão, com λ_{max} (em nm) como variável-alvo.

2. Conjunto de Dados

O treinamento do modelo será realizado sobre o Deep4Chem (Joung et al., 2020), base de dados pública disponível via Figshare (DOI: 10.6084/m9.figshare.12045567.v2). O Deep4Chem compila propriedades ópticas experimentais de 7.016 cromóforos orgânicos únicos em 365 solventes, totalizando 20.236 registros extraídos de 1.358 artigos científicos. Cada entrada contém o SMILES do cromóforo, o SMILES do solvente, λ_{abs} , λ_{em} , coeficiente de extinção molar e rendimento quântico.

Na Etapa 2, o modelo treinado será aplicado sobre as 5.974 moléculas do conjunto proprietário, representadas pela coluna de SMILES canônicos. Esse conjunto não possui rótulos de λ_{max} , sendo utilizado exclusivamente para triagem exploratória e não para treino ou avaliação do modelo.

3. Abordagem Proposta

A estratégia é dividida em duas etapas distintas. Na Etapa 1, duas arquiteturas serão treinadas e comparadas sobre o Deep4Chem:

- Baseline: MLP com fingerprints Morgan: os SMILES serão convertidos em vetores binários de 2.048 bits (raio 2) via RDKit, utilizados como entrada de uma rede MLP totalmente conectada. Serve como referência por ser rápido, interpretável e bem estabelecido na literatura de quimioinformática.
- Modelo principal: LSTM bidirecional sobre SMILES: cada caractere do SMILES será mapeado a um embedding treinável e processado por uma LSTM bidirecional, cuja representação final alimentará camadas densas para predição de λ_{max} .

Ambos os modelos serão implementados em PyTorch e treinados no Google Colab (GPU gratuita), adotando divisão 80/20 para treino e teste, com validação cruzada para seleção de hiperparâmetros. A métrica principal será o Erro Médio Absoluto (MAE, em nm). Na Etapa 2, o melhor modelo resultante será aplicado diretamente sobre as 5.974 moléculas proprietárias para gerar um ranking de λ_{max} previsto, identificando candidatos prioritários para síntese experimental.

Referência: Joung et al. (2020). Experimental database of optical properties of organic compounds. Scientific Data, 7, 295. DOI: 10.1038/s41597-020-00634-8