

Predição de λ_{max} de Moléculas Orgânicas via Aprendizado Profundo: Comparação de Arquiteturas e Aplicação em Triagem Computacional

Crhisângela Ferreira¹

¹Programa de Pós-Graduação em Ciência da Computação
Universidade Federal do ABC (UFABC)
CCM-109 – Tópicos Especiais em Inteligência Artificial

`crhisangela.ferreira@ufabc.edu.br`

Resumo. A predição do comprimento de onda de máxima absorção (λ_{max}) de moléculas orgânicas é relevante para o desenvolvimento de corantes, sensores e fotocatalisadores, mas os métodos quânticos de referência (DFT) têm custo computacional elevado demais para triagens em larga escala. Neste trabalho treinamos e comparamos três abordagens obrigatórias – MLP com fingerprints Morgan, Gradient Boosting sobre descritores RDKit e Bi-LSTM bidirecional sobre SMILES – e uma extensão opcional de estado da arte (D-MPNN/Chemprop), para prever λ_{max} a partir do SMILES do cromóforo e do solvente, usando o dataset público Deep4Chem. O melhor modelo é então aplicado, com quantificação de incerteza (MC-Dropout ou ensemble bootstrap, conforme o modelo), a um conjunto proprietário de 5.974 moléculas geradas computacionalmente, com o objetivo de priorizar candidatos à síntese experimental. Numa execução preliminar de validação do pipeline, sobre uma subamostra reduzida do Deep4Chem, o Gradient Boosting obteve o melhor desempenho (MAE de 44,5 nm no teste); a análise de deslocamento de distribuição, por sua vez, revelou diferenças estatisticamente significativas entre o Deep4Chem e o conjunto proprietário, o que recomenda cautela na transferência do modelo.

Abstract. Predicting the wavelength of maximum absorption (λ_{max}) of organic molecules matters for the development of dyes, sensors and photocatalysts, but reference quantum-chemical methods (DFT) are too computationally expensive for large-scale screening. We train and compare three required approaches – an MLP over Morgan fingerprints, Gradient Boosting over RDKit descriptors, and a bidirectional LSTM over SMILES – plus an optional state-of-the-art extension (D-MPNN/Chemprop), to predict λ_{max} from the chromophore and solvent SMILES, using the public Deep4Chem dataset. The best model is then applied, with uncertainty quantification (MC-Dropout or bootstrap ensembling, depending on the model), to a proprietary set of 5,974 computationally generated molecules, in order to prioritize candidates for experimental synthesis. In a preliminary pipeline-validation run on a reduced subsample of Deep4Chem, Gradient Boosting achieved the best performance (test MAE of 44.5 nm); a distribution-shift analysis further revealed statistically significant differences between Deep4Chem and the proprietary set, which argues for caution when transferring the model.

1. Descrição do Problema

A predição de propriedades ópticas de moléculas orgânicas é um problema central em quimioinformática e no desenvolvimento de novos materiais. O comprimento de onda de máxima absorção (λ_{max}) no espectro UV-Vis, em particular, condiciona aplicações em corantes, sensores e fotocatalisadores. Métodos baseados na Teoria do Funcional da Densidade (DFT) [Hohenberg and Kohn 1964, Kohn and Sham 1965], em sua formulação dependente do tempo (TD-DFT) [Adamo and Jacquemin 2013], calculam estados excitados e λ_{max} com boa precisão, mas o custo computacional torna inviável a triagem em larga escala sobre espaços moleculares amplos.

Formulamos o problema como uma tarefa de regressão supervisionada: dado o SMILES de um cromóforo e o SMILES do solvente em que ele é medido, prever λ_{max} em nanômetros. O solvente entra como variável de entrada porque λ_{max} é sensível ao ambiente químico (efeitos solvatocrômicos) [Reichardt 1994], não apenas à estrutura do cromóforo isolado.

O projeto tem duas etapas. Na primeira, os modelos são treinados e comparados sobre um dataset público rotulado, buscando a abordagem com melhor generalização. Na segunda, o modelo escolhido é aplicado como ferramenta de triagem exploratória sobre um conjunto proprietário de 5.974 moléculas sem rótulo – geradas computacionalmente por um aluno de iniciação científica do laboratório ABC Sim da UFABC –, produzindo um ranking de candidatos prioritários para síntese experimental.

1.1. Motivação

Na prática, o projeto busca substituir cálculos DFT custosos, para fins de triagem inicial, por um modelo treinado sobre dados experimentais, capaz de prever λ_{max} para milhares de moléculas em segundos. Isso interessa diretamente ao laboratório ABC Sim, que já tem um espaço de moléculas geradas computacionalmente e precisa de algum critério para decidir quais estruturas vale a pena sintetizar e caracterizar.

1.2. Definição Formal da Tarefa

Seja s_c o SMILES do cromóforo e s_v o SMILES do solvente. O objetivo é aprender uma função $f(s_c, s_v) \rightarrow \hat{y}$, em que $\hat{y}$ é a predição de λ_{max} em nanômetros, minimizando o Erro Médio Absoluto (MAE) entre $\hat{y}$ e o valor experimental y em um conjunto de teste mantido separado do treino.

2. Abordagem

2.1. Conjunto de Dados

O treinamento e a avaliação dos modelos usam o Deep4Chem [Joung et al. 2020], base pública disponível via Figshare (DOI: 10.6084/m9.figshare.12045567.v2), que compila propriedades ópticas experimentais de 7.016 cromóforos orgânicos únicos medidos em 365 solventes distintos – 20.236 registros ao todo, extraídos de 1.358 artigos científicos. Cada entrada traz o SMILES do cromóforo, o SMILES do solvente, λ_{abs} , λ_{em} , coeficiente de extinção molar e rendimento quântico; deste conjunto, usamos apenas SMILES do cromóforo, SMILES do solvente e λ_{abs} (renomeado `lambda_max`).

Na Etapa 2, o modelo treinado é aplicado sobre o conjunto proprietário de 5.974 moléculas (`resources/banco_smiles_aromatizados.parquet`), representadas por SMILES canônicos e por colunas que rastreiam os anéis/fragmentos de origem de cada molécula. Esse conjunto não tem rótulos de λ_{max} ; serve só para triagem exploratória, nunca para treino ou avaliação.




Figura 1. Análise exploratória do Deep4Chem. Esquerda: distribuição do λ_{max} experimental. Direita: os 10 solventes mais frequentes no dataset.

A Figura 1 mostra essa distribuição, concentrada majoritariamente entre 300 e 500 nm com uma cauda longa até o infravermelho próximo, e os 10 solventes mais frequentes, liderados por diclorometano (ClCCl) – por isso a escolha desse solvente como referência constante na Etapa 2 (Seção 2.5).

2.2. Pré-processamento

Os SMILES do Deep4Chem são validados com o RDKit [RDKit 2024] (`Chem.MolFromSmiles`); descartamos registros com valores ausentes ou SMILES inválidos e removemos duplicatas por par (cromóforo, solvente). Como λ_{max} depende do solvente, o SMILES do solvente é mantido como feature em todos os modelos.

Parsing tolerante do conjunto proprietário. Ao contrário do Deep4Chem, cerca de metade dos SMILES do conjunto proprietário usa notação de aromaticidade explícita com o símbolo `:` entre átomos maiúsculos (não aromáticos na notação padrão), o que faz o parser padrão do RDKit falhar ao tentar kekulizar a molécula (*Can't kekulize mol*). Nesses casos, refazemos o parsing com `sanitize=False` seguido de `Chem.SanitizeMol` com a flag `SANITIZE_KEKULIZE` desabilitada, o que preserva a informação de aromaticidade sem exigir uma estrutura de Kekulé explícita. Essa mudança elevou a taxa de parsing do conjunto proprietário de $\approx 49\%$ para 100% (5.974/5.974 moléculas).

Divisão dos dados (scaffold split). Em vez de uma divisão aleatória, adotamos um *scaffold split* por molécula, baseado no arcabouço de Bemis-Murcko [Bemis and Murcko 1996]: todas as ocorrências de uma mesma família estrutural (scaffold) do cromóforo ficam inteiramente no treino ou inteiramente no teste (80%/20%). Isso evita que o mesmo esqueleto molecular apareça nos dois conjuntos, o que superestimaria a generalização do modelo numa divisão aleatória – ponto incorporado a partir do feedback recebido sobre a proposta inicial.

2.3. Modelos

Implementamos e comparamos três abordagens obrigatórias, todas em PyTorch [Paszke et al. 2019]/scikit-learn [Pedregosa et al. 2011]:

- *Baseline 1 – MLP com fingerprints Morgan.* Os SMILES do cromóforo e do solvente são convertidos em vetores binários via fingerprints de Morgan [Rogers and Hahn 2010] (2.048 bits para o cromóforo, 256 bits para o solvente, raio 2, calculados com RDKit) e concatenados como entrada de uma rede totalmente conectada, com camadas ocultas de até 512 e 256 unidades, ativação ReLU e *dropout* [Srivastava et al. 2014].
- *Baseline 2 (forte) – Gradient Boosting sobre descritores RDKit.* Um GradientBoostingRegressor [Friedman 2001] treinado sobre ≈ 217 descritores físico-químicos do RDKit (peso molecular, LogP, número de anéis aromáticos, TPSA, cargas parciais, entre outros) [Todeschini and Consonni 2009], computados tanto para o cromóforo quanto para o solvente. Entrou como comparação adicional, sugerida no feedback da proposta.
- *Modelo principal – Bi-LSTM char-level.* Cada caractere do SMILES do cromóforo é mapeado a um *embedding* treinável e processado por uma LSTM bidirecional [Hochreiter and Schmidhuber 1997, Schuster and Paliwal 1997]; a concatenação dos últimos estados forward/backward é combinada ao fingerprint Morgan do solvente (256 bits) antes de passar por camadas densas que produzem a predição final.
- *Extensão opcional – D-MPNN (Chemprop).* Rede de mensagens direcionadas sobre o grafo molecular [Gilmer et al. 2017, Yang et al. 2019], na linha dos benchmarks consolidados pelo MoleculeNet [Wu et al. 2018]. Está numa célula separada e autocontida do notebook (RUN_CHEMPROP=True), condicionada à disponibilidade da biblioteca chemprop e ao tempo de treino disponível antes da entrega.

2.4. Protocolo Experimental

Todos os modelos obrigatórios são avaliados com o mesmo scaffold split (80% treino / 20% teste). A métrica principal é o Erro Médio Absoluto (MAE, em nm), complementada pela Raiz do Erro Quadrático Médio (RMSE, em nm), seguindo a recomendação de reportar as duas em vez de só o MAE. Os hiperparâmetros (tamanho da camada oculta e *dropout* do MLP; profundidade e taxa de aprendizado do GBM; dimensão do *embedding* e da camada oculta da Bi-LSTM) são selecionados por validação cruzada em grupos de scaffold (GroupKFold agrupado pelo mesmo scaffold de Bemis-Murcko do split externo), o que evita que a mesma família estrutural apareça ao mesmo tempo em treino e validação de um fold.

2.5. Etapa 2 – Aplicação e Quantificação de Incerteza

O modelo com melhor desempenho na Etapa 1 é aplicado ao conjunto proprietário para gerar um ranking de λ_{max} previsto. Como esse conjunto não tem solvente rotulado, usamos como referência constante o solvente mais frequente no Deep4Chem (diclorometano, ClCCl) – uma simplificação que precisa ser ajustada conforme o contexto experimental real do laboratório ABC Sim.

Como esse ranking vai guiar decisões de síntese, incluímos quantificação de incerteza, escolhida de acordo com o modelo vencedor. Para os modelos neurais (MLP ou Bi-LSTM), usamos MC-Dropout [Gal and Ghahramani 2016, Srivastava et al. 2014]: o modelo permanece em modo de treinamento (*dropout* ativo) durante a inferência, e múltiplas passadas sobre a mesma molécula geram uma distribuição de predições cujo desvio-padrão serve de proxy de incerteza. Para o Gradient Boosting, que não tem *dropout*, treinamos em seu lugar um pequeno ensemble bootstrap de modelos com os mesmos hiperparâmetros, sementes e subamostras (*subsample*) distintas, seguindo a lógica de ensembles preditivos para quantificação de incerteza [Lakshminarayanan et al. 2017]; a dispersão entre as predições cumpre o mesmo papel. Nos dois casos, candidatos de alta confiança (baixa variância entre passadas/modelos) são priorizados no ranking final.

Também comparamos a distribuição do Deep4Chem com a do conjunto proprietário (*domain shift*), usando o teste de Kolmogorov-Smirnov sobre descritores moleculares-chave (peso molecular, LogP, TPSA, doadores/aceptores de ligação de hidrogênio, anéis aromáticos, ligações rotacionáveis), para estimar até que ponto a transferência do modelo é confiável.

3. Resultados

Nota sobre o status dos resultados. Os números desta seção vêm de uma execução de validação do pipeline (`QUICK_TEST=True` no notebook), sobre uma subamostra de 1.500 registros do Deep4Chem e com poucas épocas de treino – o objetivo aqui era só confirmar que o código roda de ponta a ponta sem erros antes da execução completa. Não são os resultados finais: a execução completa (`QUICK_TEST=False`, dataset inteiro, Google Colab com GPU) ainda falta ser feita e deve substituir as tabelas abaixo na entrega final. Mesmo assim, já dá para tirar algumas leituras interessantes deles, discutidas a seguir.

3.1. Comparação entre modelos (Etapa 1)

A Tabela 1 mostra o desempenho dos três modelos obrigatórios no conjunto de teste (scaffold split), nessa execução sobre 1.500 registros (1.216 de treino / 284 de teste, 0 scaffolds em comum entre os conjuntos).

Tabela 1. Comparação de desempenho dos modelos na Etapa 1 (conjunto de teste, scaffold split; subamostra de validação do pipeline).

Modelo	MAE (nm)	RMSE (nm)
Gradient Boosting (descritores RDKit)	44,5	60,5
MLP + fingerprints Morgan	51,1	70,7
Bi-LSTM (SMILES + solvente)	81,5	109,8
D-MPNN (Chemprop, opcional)	–	–

Nessa rodada reduzida, o Gradient Boosting superou tanto o MLP quanto a Bi-LSTM. Os descritores RDKit mais importantes para o modelo foram, em ordem: MaxAbsPartialCharge, NumAliphaticHeterocycles, fr_allylic_oxid, SMR_VSA10, BCUT2D_MRLow, PEOE_VSA8, BertzCT, MinPartialCharge, Chi3n e NumAliphaticRings, o que é coerente com a expectativa química de que




Figura 2. Esquerda: MAE de teste por modelo. Direita: dispersão λ_{max} previsto vs. real para o melhor modelo (Gradient Boosting).

cargas parciais e complexidade estrutural/eletrônica se associam à posição de λ_{max} . Já a Bi-LSTM, apesar de ser o modelo principal do projeto, teve o pior desempenho nessa rodada; a hipótese mais provável, a confirmar na execução completa (Seção 4), é que redes treinadas do zero sobre representações *char-level* precisam de mais dados e épocas para convergir do que os 1.216 exemplos de treino desta subamostra permitem.

3.2. Etapa 2 – Ranking e incerteza

O modelo vencedor da Etapa 1 nessa rodada (Gradient Boosting) foi aplicado às 5.974 moléculas do conjunto proprietário, com o solvente de referência constante C1CC1 (diclorometano) e quantificação de incerteza por ensemble bootstrap (5 modelos). A Tabela 2 resume a distribuição do λ_{max} previsto e da incerteza (desvio-padrão entre modelos do ensemble); a Figura 3 mostra a distribuição do ranking e a relação entre λ_{max} previsto e incerteza.

Tabela 2. Estatísticas descritivas do ranking de λ_{max} previsto para as 5.974 moléculas proprietárias.

Estatística	λ_{max} previsto (nm)	Incerteza – desvio padrão (nm)
Média	466,4	21,5
Desvio padrão	53,2	7,4
Mínimo	321,8	2,3
1º quartil	428,6	16,3
Mediana	464,2	21,2
3º quartil	503,2	26,4
Máximo	670,0	51,2

Selecionamos os candidatos prioritários para síntese combinando alto λ_{max} previsto e incerteza abaixo da mediana; entre os 15 candidatos de maior λ_{max} previsto nessas condições, os valores variam entre 600 e 647 nm, com incerteza entre 8,6 e 21,2 nm. O ranking completo, com as colunas de proveniência (anéis/fragmentos de origem), é




Figura 3. Esquerda: distribuição do λ_{max} previsto para o conjunto proprietário. Direita: λ_{max} previsto vs. incerteza, com a mediana da incerteza como referência para a triagem de candidatos de alta confiança.

exportado em `resources/ranking_lambda_max_proprietario.csv` para uso direto pelo laboratório ABC Sim.

3.3. Deslocamento de distribuição (*domain shift*)

A Tabela 3 e a Figura 4 comparam a distribuição de sete descritores moleculares-chave entre os cromóforos de treino do Deep4Chem e as moléculas do conjunto proprietário, via teste de Kolmogorov-Smirnov (hipótese nula: mesma distribuição).

Tabela 3. Deslocamento de distribuição entre o Deep4Chem (treino) e o conjunto proprietário, ordenado por estatística KS decrescente. Todos os p -valores $< 10^{-180}$.

Descritor	Média Deep4Chem	Média proprietário	KS
NumHAcceptors	3,45	8,81	0,747
TPSA	50,35	148,06	0,745
NumHDonors	0,49	3,13	0,737
NumAromaticRings	4,21	0,92	0,714
MolLogP	6,51	1,39	0,618
NumRotatableBonds	5,10	8,53	0,531
MolWt	456,15	524,57	0,448

O deslocamento de distribuição é acentuado nos sete descritores avaliados (KS entre 0,45 e 0,75, todos com $p < 10^{-180}$). As moléculas proprietárias são, em média, bem mais polares (TPSA quase $3\times$ maior) e ricas em doadores/aceptores de ligação de hidrogênio, mas têm menos anéis aromáticos e LogP menor que os cromóforos do Deep4Chem. Como o Deep4Chem é composto majoritariamente por corantes e cromóforos aromáticos conjugados, e o conjunto proprietário parece ocupar uma região mais polar e menos aromática do espaço químico, isso é evidência direta de que a transferência do modelo deve ser tratada com cautela – ponto retomado na Seção 4.




Figura 4. Distribuições sobrepostas de descritores-chave: Deep4Chem (treino) vs. conjunto proprietário.

4. Lições Aprendidas

O scaffold split foi implementado e validado corretamente: a interseção de scaffolds entre treino e teste deu zero em todas as execuções. A busca de hiperparâmetros por validação cruzada em grupos de scaffold (`GroupKFold`) também funcionou de forma estável para os três modelos, sem precisar de alteração de código entre a execução de validação e a execução completa.

O parsing do conjunto proprietário deu mais trabalho do que o esperado. Cerca de metade dos seus SMILES usa aromaticidade explícita com o símbolo `:` entre átomos não declarados como aromáticos, algo que o parser padrão do RDKit rejeita por falha de kekulização. Resolvemos reparsingando com `sanitize=False` e pulando apenas a etapa `SANITIZE_KEKULIZE`, o que elevou a taxa de sucesso de $\approx 49\%$ para 100% ; essa decisão ficou documentada explicitamente no notebook, e não como um contorno silencioso escondido no código.

Também apareceu um bug sutil de overflow numérico: ao calcular os ≈ 217 descritores RDKit por molécula para o Gradient Boosting, o descritor `IpC` (índice de conteúdo de informação) assume valores absurdamente grandes para moléculas maiores, o que causava overflow silencioso ao converter para `float32` e quebrava o treino do GBM com um `ValueError` de valores não finitos. A correção foi limitar (*clip*) os descritores a um intervalo numérico seguro antes da conversão de tipo – um lembrete de que descritores químicos têm escalas bem heterogêneas e não podem ser usados sem algum tratamento de outliers.

Uma decisão que ainda merece revisão é a do solvente de referência constante (diclorometano, o mais frequente no Deep4Chem) usado na Etapa 2, já que o conjunto proprietário não tem solvente rotulado. É uma simplificação razoável para destravar o pipeline, mas deveria ser validada com o laboratório ABC Sim: o solvente efetivamente usado na caracterização das amostras pode ser outro e, dado o efeito solvatocrômico, isso influencia diretamente o λ_{max} previsto.

O maior risco do projeto, no entanto, é o deslocamento de distribuição discutido

na Seção 3.3: o conjunto proprietário ocupa uma região do espaço químico sistematicamente diferente do Deep4Chem (mais polar, menos aromática). Isso quer dizer que um bom desempenho no teste do Deep4Chem não garante confiabilidade quando o modelo é aplicado ao conjunto proprietário, o que reforça a importância de manter a quantificação de incerteza (Seção 2.5) em vez de tratar todas as previsões da Etapa 2 com o mesmo grau de confiança.

Como próximos passos, pretendemos: (i) rodar o notebook completo com `QUICK_TEST=False` no Google Colab (GPU) sobre o Deep4Chem inteiro e substituir as Tabelas 1–3 pelos resultados finais – esperamos que a Bi-LSTM, que precisa de mais dados para convergir, melhore de posição relativa ao GBM com o dataset completo; (ii) treinar a extensão opcional D-MPNN (Chemprop) como comparação de estado da arte, se der tempo; (iii) comparar o scaffold split com um split aleatório de controle, para reportar quantitativamente o quanto o scaffold split é de fato mais conservador.

5. Conclusão

O projeto tinha três critérios de sucesso: viabilidade do pipeline, desempenho preditivo dos modelos e confiabilidade da aplicação ao conjunto proprietário. Nesta execução preliminar, o resultado é misto, e vale detalhar por quê.

Do ponto de vista de viabilidade, o pipeline funciona: o código roda de ponta a ponta sem erros, o scaffold split foi implementado e validado corretamente (interseção de scaffolds entre treino e teste sempre igual a zero), a validação cruzada em grupos de scaffold é estável nos três modelos, e o parsing tolerante elevou a cobertura do conjunto proprietário de $\approx 49\%$ para 100%. Nesse quesito, o objetivo foi cumprido.

Já a pergunta de qual arquitetura é melhor segue em aberto. Nesta execução reduzida (1.500 registros, poucas épocas), o Gradient Boosting teve o menor MAE (44,5 nm), à frente do MLP (51,1 nm) e, com folga, da Bi-LSTM (81,5 nm) – que é o modelo principal proposto no projeto. Isoladamente esse ranking não permite concluir qual arquitetura é superior: a Bi-LSTM é treinada do zero, sem pré-treino, e é conhecida por precisar de mais dados e épocas para convergir do que os ≈ 1.216 exemplos usados aqui, de modo que seu desempenho fraco é mais provavelmente um efeito do tamanho reduzido da amostra do que uma limitação real da arquitetura. Essa comparação só terá uma resposta consistente depois da execução completa (`QUICK_TEST=False`) sobre o Deep4Chem inteiro.

O ponto mais delicado é a confiabilidade da aplicação ao conjunto proprietário. A análise de deslocamento de distribuição apontou diferenças estatisticamente muito significativas ($p < 10^{-180}$) nos sete descritores moleculares comparados, com estatística de Kolmogorov-Smirnov entre 0,45 e 0,75 – valores altos, que indicam que o conjunto proprietário ocupa uma região do espaço químico bastante diferente da usada no treino (mais polar, com mais doadores/aceptores de ligação de hidrogênio, menos aromática). Mesmo com o Gradient Boosting tendo o melhor MAE no teste do Deep4Chem, essa evidência mostra que sua previsão para as 5.974 moléculas do laboratório ABC Sim não deve ser tomada como confiável sem validação experimental adicional. É por isso que a quantificação de incerteza (Seção 2.5) e a filtragem por baixa variância entraram no ranking final: o resultado da Etapa 2 serve como critério de priorização exploratória, não como previsão quantitativa validada.

Em resumo, a abordagem é tecnicamente viável – pipeline correto, modelos

treináveis, incerteza quantificável –, mas os números desta execução preliminar não permitem afirmar que o modelo generaliza bem para o conjunto proprietário: o sinal de deslocamento de distribuição já é forte o bastante para justificar cautela, e a comparação entre arquiteturas segue sem resposta até a execução completa. O pipeline funciona; a pergunta que realmente importa – qual modelo é confiável para priorizar síntese no conjunto proprietário – ainda não tem resposta, e é essa lacuna que a execução completa, descrita na Seção 4, deve fechar.

6. Reprodutibilidade

O código completo do projeto (pré-processamento, treinamento dos modelos, avaliação e aplicação na Etapa 2) está disponível em: <https://github.com/crhisangela/ai-ronaldo>.

O repositório inclui o notebook `main.ipynb`, usado para todos os experimentos, com um flag `QUICK_TEST` que alterna entre uma execução reduzida de validação do pipeline (usada para gerar os resultados preliminares desta seção) e a execução completa sobre o Deep4Chem inteiro. O Deep4Chem é baixado automaticamente do Figshare na primeira execução e mantido em cache local (`resources/deep4chem_raw/`); o conjunto proprietário é lido de `resources/banco_smiles_aromatizados.parquet`.

Referências

- Adamo, C. and Jacquemin, D. (2013). The calculations of excited-state properties with time-dependent density functional theory. *Chemical Society Reviews*, 42(3):845–856.
- Bemis, G. W. and Murcko, M. A. (1996). The properties of known drugs. 1. molecular frameworks. *Journal of Medicinal Chemistry*, 39(15):2887–2893.
- Friedman, J. H. (2001). Greedy function approximation: A gradient boosting machine. *The Annals of Statistics*, 29(5):1189–1232.
- Gal, Y. and Ghahramani, Z. (2016). Dropout as a bayesian approximation: Representing model uncertainty in deep learning. In *Proceedings of the 33rd International Conference on Machine Learning (ICML)*, pages 1050–1059.
- Gilmer, J., Schoenholz, S. S., Riley, P. F., Vinyals, O., and Dahl, G. E. (2017). Neural message passing for quantum chemistry. In *Proceedings of the 34th International Conference on Machine Learning (ICML)*, pages 1263–1272.
- Hochreiter, S. and Schmidhuber, J. (1997). Long short-term memory. *Neural Computation*, 9(8):1735–1780.
- Hohenberg, P. and Kohn, W. (1964). Inhomogeneous electron gas. *Physical Review*, 136(3B):B864–B871.
- Joung, J. F., Han, M., Jeong, J., and Park, S. (2020). Experimental database of optical properties of organic compounds. *Scientific Data*, 7:295.
- Kohn, W. and Sham, L. J. (1965). Self-consistent equations including exchange and correlation effects. *Physical Review*, 140(4A):A1133–A1138.

- Lakshminarayanan, B., Pritzel, A., and Blundell, C. (2017). Simple and scalable predictive uncertainty estimation using deep ensembles. In *Advances in Neural Information Processing Systems (NeurIPS)*, pages 6402–6413.
- Paszke, A., Gross, S., Massa, F., et al. (2019). Pytorch: An imperative style, high-performance deep learning library. In *Advances in Neural Information Processing Systems (NeurIPS)*, pages 8026–8037.
- Pedregosa, F., Varoquaux, G., Gramfort, A., et al. (2011). Scikit-learn: Machine learning in python. *Journal of Machine Learning Research*, 12:2825–2830.
- RDKit (2024). Rdkit: Open-source cheminformatics. <https://www.rdkit.org>.
- Reichardt, C. (1994). Solvatochromic dyes as solvent polarity indicators. *Chemical Reviews*, 94(8):2319–2358.
- Rogers, D. and Hahn, M. (2010). Extended-connectivity fingerprints. *Journal of Chemical Information and Modeling*, 50(5):742–754.
- Schuster, M. and Paliwal, K. K. (1997). Bidirectional recurrent neural networks. *IEEE Transactions on Signal Processing*, 45(11):2673–2681.
- Srivastava, N., Hinton, G., Krizhevsky, A., Sutskever, I., and Salakhutdinov, R. (2014). Dropout: A simple way to prevent neural networks from overfitting. *Journal of Machine Learning Research*, 15(1):1929–1958.
- Todeschini, R. and Consonni, V. (2009). *Molecular Descriptors for Chemoinformatics*. Wiley-VCH, Weinheim.
- Wu, Z., Ramsundar, B., Feinberg, E. N., et al. (2018). Moleculenet: A benchmark for molecular machine learning. *Chemical Science*, 9(2):513–530.
- Yang, K., Swanson, K., Jin, W., et al. (2019). Analyzing learned molecular representations for property prediction. *Journal of Chemical Information and Modeling*, 59:3370–3388.