

Predição de λ_{max} de Moléculas Orgânicas via Aprendizado Profundo: Comparação de Arquiteturas e Aplicação em Triagem Computacional

Crhisângela Ferreira¹

¹Programa de Pós-Graduação em Ciência da Computação – Universidade Federal do ABC (UFABC)
CCM-109 – Tópicos Especiais em Inteligência Artificial

[A PREENCHER: e-mail institucional ou de contato]

Resumo. A predição do comprimento de onda de máxima absorção (λ_{max}) de moléculas orgânicas é relevante para o desenvolvimento de corantes, sensores e fotocatalisadores, mas métodos quânticos de referência (DFT) têm custo computacional elevado para triagens em larga escala. Este trabalho treina e compara quatro abordagens – MLP com fingerprints Morgan, Gradient Boosting sobre descritores RDKit, LSTM bidirecional sobre SMILES e, opcionalmente, uma rede de mensagens direcionadas (D-MPNN) – para prever λ_{max} a partir do SMILES do cromóforo e do solvente, usando o dataset público Deep4Chem. O melhor modelo é então aplicado, com quantificação de incerteza via MC-Dropout, a um conjunto proprietário de 5.974 moléculas geradas computacionalmente, para priorizar candidatos à síntese experimental. [A PREENCHER: completar o resumo com o resultado quantitativo principal (ex.: MAE do melhor modelo) assim que os experimentos finais estiverem concluídos].

Abstract. [A PREENCHER: traduzir o resumo para o inglês (abstract) após finalizar o "resumo" em português]

1. Descrição do Problema

A predição de propriedades ópticas de moléculas orgânicas é um desafio central em quimioinformática e no desenvolvimento de novos materiais. Em particular, o comprimento de onda de máxima absorção (λ_{max}) no espectro UV-Vis determina aplicações em corantes, sensores e fotocatalisadores. Métodos quânticos como a Teoria do Funcional da Densidade (DFT) permitem calcular λ_{max} com boa precisão, mas seu custo computacional elevado inviabiliza a triagem em larga escala sobre espaços moleculares amplos.

Este trabalho formula o problema como uma tarefa de regressão supervisionada: dado o SMILES de um cromóforo e o SMILES do solvente em que ele é medido, prever o valor de λ_{max} (em nanômetros). A escolha de incluir o solvente como entrada decorre do fato de que λ_{max} é sensível ao ambiente químico (efeitos solvatocrômicos), e não apenas à estrutura do cromóforo isolado.

O projeto é dividido em duas etapas. Na **Etapa 1**, modelos são treinados e comparados sobre um dataset público rotulado, com o objetivo de identificar a abordagem com melhor generalização. Na **Etapa 2**, o modelo selecionado é aplicado como ferramenta de

triagem exploratória sobre um conjunto proprietário de 5.974 moléculas sem rótulo, geradas computacionalmente por um aluno de iniciação científica do laboratório ABC Sim da UFABC, produzindo um ranking de candidatos prioritários para síntese experimental.

1.1. Motivação

A motivação prática do projeto é substituir, para fins de triagem inicial, cálculos DFT custosos por um modelo de aprendizado de máquina treinado sobre dados experimentais, capaz de gerar previsões em escala para milhares de moléculas em segundos. Isso é particularmente relevante para o laboratório ABC Sim, que já dispõe de um espaço de moléculas geradas computacionalmente e precisa de um critério eficiente para priorizar quais estruturas sintetizar e caracterizar experimentalmente.

1.2. Definição Formal da Tarefa

Seja s_c o SMILES do cromóforo e s_v o SMILES do solvente. O objetivo é aprender uma função $f(s_c, s_v) \rightarrow \hat{y}$, em que $\hat{y}$ é a previsão de λ_{max} em nanômetros, minimizando o Erro Médio Absoluto (MAE) entre $\hat{y}$ e o valor experimental y em um conjunto de teste mantido separado do treino.

2. Abordagem

2.1. Conjunto de Dados

O treinamento e a avaliação dos modelos foram realizados sobre o **Deep4Chem** [Joung et al. 2020], base de dados pública disponível via Figshare (DOI: 10.6084/m9.figshare.12045567.v2). O Deep4Chem compila propriedades ópticas experimentais de 7.016 cromóforos orgânicos únicos medidos em 365 solventes distintos, totalizando 20.236 registros extraídos de 1.358 artigos científicos. Cada entrada contém o SMILES do cromóforo, o SMILES do solvente, λ_{abs} , λ_{em} , coeficiente de extinção molar e rendimento quântico; para este trabalho, apenas o SMILES do cromóforo, o SMILES do solvente e λ_{abs} (renomeado `lambda_max`) foram utilizados.

Na Etapa 2, o modelo treinado é aplicado sobre um conjunto proprietário de 5.974 moléculas, representadas por SMILES canônicos e por colunas de identificação que rastreiam os anéis/fragmentos de origem de cada molécula. Esse conjunto não possui rótulos de λ_{max} e é usado exclusivamente para triagem exploratória, nunca para treino ou avaliação.

2.2. Pré-processamento

Os SMILES foram validados com o RDKit [RDKit 2024] (parsing bem-sucedido via `Chem.MolFromSmiles`), descartando-se registros inválidos ou incompletos. Como λ_{max} depende do solvente, o SMILES do solvente foi mantido como feature em todos os modelos, e não descartado no pré-processamento.

Divisão dos dados (scaffold split). Em vez de uma divisão aleatória entre treino e teste, foi adotado um *scaffold split* por molécula, baseado no arcabouço de Bemis-Murcko [Bemis and Murcko 1996]: todas as ocorrências de uma mesma família estrutural (scaffold) são mantidas inteiramente no treino ou inteiramente no teste. Essa escolha evita que o mesmo esqueleto molecular apareça em treino e teste, o que superestimaria a capacidade de generalização do modelo caso fosse usada uma divisão aleatória – recomendação incorporada a partir do feedback recebido sobre a proposta inicial do projeto.

2.3. Modelos

Foram implementadas e comparadas quatro abordagens, todas em PyTorch/scikit-learn, treinadas no Google Colab (GPU gratuita):

- **Baseline 1 – MLP com fingerprints Morgan.** Os SMILES do cromóforo e do solvente são convertidos em vetores binários via fingerprints de Morgan [Rogers and Hahn 2010] (2.048 bits, raio 2, calculados com RDKit) e concatenados como entrada de uma rede totalmente conectada (MLP) com camadas ocultas de 512 e 256 unidades, ativação ReLU e *dropout*.
- **Baseline 2 (forte) – Gradient Boosting sobre descritores RDKit.** Um `GradientBoostingRegressor` [Friedman 2001] (500 estimadores, profundidade máxima 4, taxa de aprendizado 0,05) é treinado sobre descritores físico-químicos calculados diretamente pelo RDKit (peso molecular, LogP, número de anéis aromáticos, entre outros), incorporado como comparação adicional sugerida no feedback da proposta.
- **Modelo principal – LSTM bidirecional *char-level*.** Cada caractere do SMILES do cromóforo é mapeado a um *embedding* treinável e processado por uma LSTM bidirecional [Schuster and Paliwal 1997]; sua representação final é concatenada ao fingerprint Morgan do solvente (256 bits) antes de passar por camadas densas que produzem a predição final.
- **Extensão opcional – D-MPNN (Chemprop).** Uma rede de mensagens direcionadas sobre o grafo molecular [Yang et al. 2019], incluída como comparação de estado da arte, condicionada à disponibilidade de tempo para treino (célula opcional no notebook, requer a biblioteca `chemprop`).

2.4. Protocolo Experimental

Todos os modelos foram avaliados com o mesmo scaffold split (80% treino / 20% teste), e a métrica principal reportada é o Erro Médio Absoluto (MAE, em nm), complementada pela Raiz do Erro Quadrático Médio (RMSE, em nm) – ambas incorporadas a partir da recomendação de reportar as duas métricas em vez de apenas o MAE. Hiperparâmetros foram selecionados por validação cruzada sobre o conjunto de treino.

2.5. Etapa 2 – Aplicação e Quantificação de Incerteza

O modelo com melhor desempenho na Etapa 1 é aplicado ao conjunto proprietário de 5.974 moléculas para gerar um ranking de λ_{max} previsto. Como o conjunto proprietário não possui um solvente rotulado, foi adotado um solvente de referência constante para todas as predições – decisão que deve ser ajustada conforme o contexto experimental real do laboratório ABC Sim (por exemplo, o solvente mais frequente no Deep4Chem, ou o de interesse direto do laboratório).

Como esse ranking guiará decisões de síntese experimental, foi incorporada quantificação de incerteza via *MC-Dropout* [Gal and Ghahramani 2016]: o modelo é mantido em modo de treinamento (*dropout* ativo) durante a inferência, e múltiplas passadas ($n = 30$) sobre a mesma molécula produzem uma distribuição de predições, cujo desvio-padrão é usado como proxy de incerteza. Candidatos de alta confiança (baixa variância entre passadas) são priorizados no ranking final. Também está prevista uma análise de deslocamento de distribuição (*domain shift*) entre o Deep4Chem e o conjunto proprietário, comparando estatísticas de descritores moleculares (peso molecular, LogP etc.) entre os dois conjuntos, para avaliar até que ponto a transferência do modelo é confiável.

3. Resultados

[A PREENCHER: Esta seção está estruturada como template. Os experimentos completos (GBM, Bi-LSTM, comparação final e aplicação na Etapa 2) ainda não haviam sido executados até a elaboração deste relatório – preencher as tabelas e figuras abaixo após rodar o notebook por completo no Google Colab, com os datasets reais.]

3.1. Resultado preliminar disponível

Até o momento, apenas o treinamento do Baseline 1 (MLP com fingerprints Morgan) foi executado, com a seguinte evolução do MAE de validação ao longo dos epochs:

Table 1. MAE de validação do MLP (fingerprints Morgan) por epoch – resultado preliminar, execução parcial.

Epoch	MAE de validação (nm)
20	36,90
40	35,04
60	33,91
80	33,80
100	[A PREENCHER: valor do epoch 100]

O valor de MAE de validação estabiliza em torno de 33,8–34 nm entre os epochs 80 e 100, sugerindo convergência do baseline nessa faixa. [A PREENCHER: comentar se esse patamar é consistente com a literatura sobre o Deep4Chem, e se há sinais de overfitting].

3.2. Comparação entre modelos (Etapa 1)

[A PREENCHER: preencher com os valores de MAE e RMSE de teste, no scaffold split, para cada modelo]

Table 2. Comparação de desempenho dos modelos na Etapa 1 (conjunto de teste, scaffold split).

Modelo	MAE (nm)	RMSE (nm)
MLP + fingerprints Morgan	[A PREENCHER: valor]	[A PREENCHER: valor]
Gradient Boosting (descritores RDKit)	[A PREENCHER: valor]	[A PREENCHER: valor]
Bi-LSTM (SMILES + solvente)	[A PREENCHER: valor]	[A PREENCHER: valor]
D-MPNN (Chemprop, opcional)	[A PREENCHER: valor]	[A PREENCHER: valor]

[A PREENCHER: Incluir aqui um gráfico (dispersão predito vs. real, ou barras de MAE por modelo) gerado a partir das saídas reais do notebook – por exemplo, com matplotlib, exportado como PNG/PDF e incluído via \includegraphics.]

3.3. Etapa 2 – Ranking e incerteza

[A PREENCHER: preencher com: (i) estatísticas descritivas do ranking de λ_{max} previsto para as 5.974 moléculas; (ii) exemplos dos candidatos de maior confiança (menor desvio-padrão via MC-Dropout); (iii) resultado da análise de deslocamento de distribuição entre Deep4Chem e o conjunto proprietário.]

4. Lições Aprendidas

[A PREENCHER: Esta seção deve ser escrita após a execução completa dos experimentos. Sugestões de pontos a cobrir, com base no protocolo adotado:]

- [A PREENCHER: O que funcionou: por exemplo, se o scaffold split revelou uma queda de desempenho em relação a um split aleatório testado como controle, evidenciando overfitting a famílias estruturais específicas.]
- [A PREENCHER: O que não funcionou ou exigiu ajuste: por exemplo, dificuldades no parsing de SMILES do Deep4Chem, necessidade de ajustar RAW_PATH/COL_MAP conforme o cabeçalho real do arquivo baixado do Figshare, ou instabilidade no treino do Bi-LSTM.]
- [A PREENCHER: Decisões de design que valeriam revisão: por exemplo, a escolha de um solvente de referência constante para a Etapa 2, dado que o conjunto proprietário não tem solvente rotulado – isso é uma limitação a ser discutida.]
- [A PREENCHER: O que seria feito diferente: por exemplo, priorizar o D-MPNN desde o início em vez de deixá-lo como extensão opcional, ou aplicar validação cruzada por scaffold (k-fold sobre scaffolds) em vez de um único split, conforme sugerido no feedback recebido.]

5. Reprodutibilidade

O código completo do projeto (pré-processamento, treinamento dos quatro modelos, avaliação e aplicação na Etapa 2) está disponível em: [A PREENCHER: inserir aqui o link do repositório (GitHub/GitLab)].

O repositório inclui o notebook utilizado para todos os experimentos, com instruções para baixar o Deep4Chem via Figshare e para ajustar os caminhos dos arquivos de entrada.

References

- Bemis, G. W. and Murcko, M. A. (1996). The properties of known drugs. 1. molecular frameworks. *Journal of Medicinal Chemistry*, 39(15):2887–2893.
- Friedman, J. H. (2001). Greedy function approximation: A gradient boosting machine. *The Annals of Statistics*, 29(5):1189–1232.
- Gal, Y. and Ghahramani, Z. (2016). Dropout as a bayesian approximation: Representing model uncertainty in deep learning. In *Proceedings of the 33rd International Conference on Machine Learning (ICML)*, pages 1050–1059.
- Joung, J. F., Han, M., Jeong, J., and Park, S. (2020). Experimental database of optical properties of organic compounds. *Scientific Data*, 7:295.

- RDKit (2024). Rdkit: Open-source cheminformatics. <https://www.rdkit.org>.
- Rogers, D. and Hahn, M. (2010). Extended-connectivity fingerprints. *Journal of Chemical Information and Modeling*, 50(5):742–754.
- Schuster, M. and Paliwal, K. K. (1997). Bidirectional recurrent neural networks. *IEEE Transactions on Signal Processing*, 45(11):2673–2681.
- Yang, K., Swanson, K., Jin, W., et al. (2019). Analyzing learned molecular representations for property prediction. In *Journal of Chemical Information and Modeling*, volume 59, pages 3370–3388.