

Predição de λ_{max} de Moléculas Orgânicas via Aprendizado Profundo: Comparação de Arquiteturas e Aplicação em Triagem Computacional

Crhisângela Ferreira¹

¹Programa de Pós-Graduação em Ciência da Computação
Universidade Federal do ABC (UFABC)
CCM-109 – Tópicos Especiais em Inteligência Artificial

ferreiracrhis@gmail.com

Resumo. A predição do comprimento de onda de máxima absorção (λ_{max}) de moléculas orgânicas é relevante para o desenvolvimento de corantes, sensores e fotocatalisadores, mas métodos quânticos de referência (DFT) têm custo computacional elevado para triagens em larga escala. Este trabalho treina e compara três abordagens obrigatórias – MLP com fingerprints Morgan, Gradient Boosting sobre descritores RDKit e Bi-LSTM bidirecional sobre SMILES –, além de uma extensão opcional de estado da arte (D-MPNN/Chemprop), para prever λ_{max} a partir do SMILES do cromóforo e do solvente, usando o dataset público Deep4Chem. O melhor modelo é então aplicado, com quantificação de incerteza (MC-Dropout ou ensemble bootstrap, conforme o modelo), a um conjunto proprietário de 5.974 moléculas geradas computacionalmente, para priorizar candidatos à síntese experimental. Em uma execução preliminar de validação do pipeline (subamostra reduzida do Deep4Chem), o Gradient Boosting obteve o melhor desempenho (MAE de 44,5 nm no teste), e a análise de deslocamento de distribuição revelou diferenças estatisticamente significativas entre o Deep4Chem e o conjunto proprietário, sinalizando cautela na transferência do modelo.

Abstract. Predicting the wavelength of maximum absorption (λ_{max}) of organic molecules is relevant for the development of dyes, sensors and photocatalysts, but reference quantum-chemical methods (DFT) are computationally expensive for large-scale screening. This work trains and compares three required approaches – an MLP over Morgan fingerprints, Gradient Boosting over RDKit descriptors, and a bidirectional LSTM over SMILES –, plus an optional state-of-the-art extension (D-MPNN/Chemprop), to predict λ_{max} from the chromophore and solvent SMILES, using the public Deep4Chem dataset. The best model is then applied, with uncertainty quantification (MC-Dropout or bootstrap ensembling, depending on the model), to a proprietary set of 5,974 computationally generated molecules, in order to prioritize candidates for experimental synthesis. In a preliminary pipeline-validation run (reduced subsample of Deep4Chem), Gradient Boosting achieved the best performance (test MAE of 44.5 nm), and the distribution-shift analysis revealed statistically significant differences

between Deep4Chem and the proprietary set, indicating that model transfer should be treated with caution.

1. Descrição do Problema

A predição de propriedades ópticas de moléculas orgânicas é um desafio central em quimioinformática e no desenvolvimento de novos materiais. Em particular, o comprimento de onda de máxima absorção (λ_{max}) no espectro UV-Vis determina aplicações em corantes, sensores e fotocatalisadores. Métodos quânticos como a Teoria do Funcional da Densidade (DFT) permitem calcular λ_{max} com boa precisão, mas seu custo computacional elevado inviabiliza a triagem em larga escala sobre espaços moleculares amplos.

Este trabalho formula o problema como uma tarefa de regressão supervisionada: dado o SMILES de um cromóforo e o SMILES do solvente em que ele é medido, prever o valor de λ_{max} (em nanômetros). A escolha de incluir o solvente como entrada decorre do fato de que λ_{max} é sensível ao ambiente químico (efeitos solvatocrômicos), e não apenas à estrutura do cromóforo isolado.

O projeto é dividido em duas etapas. Na Etapa 1, modelos são treinados e comparados sobre um dataset público rotulado, com o objetivo de identificar a abordagem com melhor generalização. Na Etapa 2, o modelo selecionado é aplicado como ferramenta de triagem exploratória sobre um conjunto proprietário de 5.974 moléculas sem rótulo, geradas computacionalmente por um aluno de iniciação científica do laboratório ABC Sim da UFABC, produzindo um ranking de candidatos prioritários para síntese experimental.

1.1. Motivação

A motivação prática do projeto é substituir, para fins de triagem inicial, cálculos DFT custosos por um modelo de aprendizado de máquina treinado sobre dados experimentais, capaz de gerar previsões em escala para milhares de moléculas em segundos. Isso é particularmente relevante para o laboratório ABC Sim, que já dispõe de um espaço de moléculas geradas computacionalmente e precisa de um critério eficiente para priorizar quais estruturas sintetizar e caracterizar experimentalmente.

1.2. Definição Formal da Tarefa

Seja s_c o SMILES do cromóforo e s_v o SMILES do solvente. O objetivo é aprender uma função $f(s_c, s_v) \rightarrow \hat{y}$, em que $\hat{y}$ é a predição de λ_{max} em nanômetros, minimizando o Erro Médio Absoluto (MAE) entre $\hat{y}$ e o valor experimental y em um conjunto de teste mantido separado do treino.

2. Abordagem

2.1. Conjunto de Dados

O treinamento e a avaliação dos modelos são realizados sobre o Deep4Chem [Joung et al. 2020], base de dados pública disponível via Figshare (DOI: 10.6084/m9.figshare.12045567.v2). O Deep4Chem compila propriedades ópticas experimentais de 7.016 cromóforos orgânicos únicos medidos em 365 solventes distintos, totalizando 20.236 registros extraídos de 1.358 artigos científicos. Cada entrada

contém o SMILES do cromóforo, o SMILES do solvente, λ_{abs} , λ_{em} , coeficiente de extinção molar e rendimento quântico; para este trabalho, apenas o SMILES do cromóforo, o SMILES do solvente e λ_{abs} (renomeado `lambda_max`) são utilizados.

Na Etapa 2, o modelo treinado é aplicado sobre o conjunto proprietário de 5.974 moléculas (`resources/banco_smiles_aromatizados.parquet`), representadas por SMILES canônicos e por colunas de identificação que rastreiam os anéis/fragmentos de origem de cada molécula. Esse conjunto não possui rótulos de λ_{max} e é usado exclusivamente para triagem exploratória, nunca para treino ou avaliação.

2.2. Pré-processamento

Os SMILES do Deep4Chem são validados com o RDKit [RDKit 2024] (`Chem.MolFromSmiles`), descartando-se registros com valores ausentes ou SMILES inválidos, e removendo-se duplicatas por par (cromóforo, solvente). Como λ_{max} depende do solvente, o SMILES do solvente é mantido como feature em todos os modelos, e não descartado no pré-processamento.

Parsing tolerante do conjunto proprietário. Ao contrário do Deep4Chem, aproximadamente metade dos SMILES do conjunto proprietário usa notação de aromaticidade explícita com o símbolo `:` entre átomos maiúsculos (não aromáticos na notação padrão), o que faz o parser padrão do RDKit falhar ao tentar kekulizar a molécula (`Can't kekulize mol`). Para esses casos, o notebook refaz o parsing com `sanitize=False` seguido de `Chem.SanitizeMol` com a flag `SANITIZE_KEKULIZE` desabilitada, preservando a informação de aromaticidade sem exigir uma estrutura de Kekulé explícita. Essa estratégia elevou a taxa de parsing do conjunto proprietário de $\approx 49\%$ para 100% (5.974/5.974 moléculas).

Divisão dos dados (`scaffold split`). Em vez de uma divisão aleatória entre treino e teste, é adotado um `scaffold split` por molécula, baseado no arcabouço de Bemis-Murcko [Bemis and Murcko 1996]: todas as ocorrências de uma mesma família estrutural (`scaffold`) do cromóforo são mantidas inteiramente no treino ou inteiramente no teste (80%/20%). Essa escolha evita que o mesmo esqueleto molecular apareça em treino e teste, o que superestimaria a capacidade de generalização do modelo caso fosse usada uma divisão aleatória – recomendação incorporada a partir do feedback recebido sobre a proposta inicial do projeto.

2.3. Modelos

São implementadas e comparadas três abordagens obrigatórias, todas em PyTorch/scikit-learn:

- Baseline 1 – MLP com fingerprints Morgan. Os SMILES do cromóforo e do solvente são convertidos em vetores binários via fingerprints de Morgan [Rogers and Hahn 2010] (2.048 bits para o cromóforo, 256 bits para o solvente, raio 2, calculados com RDKit) e concatenados como entrada de uma rede totalmente conectada (MLP) com camadas ocultas de até 512 e 256 unidades, ativação ReLU e dropout.
- Baseline 2 (forte) – Gradient Boosting sobre descritores RDKit. Um `GradientBoostingRegressor` [Friedman 2001] é treinado sobre ≈ 217 descritores

físico-químicos calculados pelo RDKit (peso molecular, LogP, número de anéis aromáticos, TPSA, cargas parciais, entre outros), computados tanto para o cromóforo quanto para o solvente – incorporado como comparação adicional sugerida no feedback da proposta.

- Modelo principal – Bi-LSTM char-level. Cada caractere do SMILES do cromóforo é mapeado a um embedding treinável e processado por uma LSTM bidirecional [Schuster and Paliwal 1997]; a concatenação dos últimos estados forward/backward é combinada ao fingerprint Morgan do solvente (256 bits) antes de passar por camadas densas que produzem a predição final.
- Extensão opcional – D-MPNN (Chemprop). Uma rede de mensagens direcionadas sobre o grafo molecular [Yang et al. 2019], incluída como comparação de estado da arte em uma célula separada e autocontida do notebook (RUN_CHEMPROP=True), condicionada à disponibilidade da biblioteca chemprop e de tempo de treino antes da entrega.

2.4. Protocolo Experimental

Todos os modelos obrigatórios são avaliados com o mesmo scaffold split (80% treino / 20% teste), e a métrica principal reportada é o Erro Médio Absoluto (MAE, em nm), complementada pela Raiz do Erro Quadrático Médio (RMSE, em nm) – ambas incorporadas a partir da recomendação de reportar as duas métricas em vez de apenas o MAE. Hiperparâmetros (tamanho da camada oculta e dropout do MLP; profundidade e taxa de aprendizado do GBM; dimensão do embedding e da camada oculta da Bi-LSTM) são selecionados por validação cruzada em grupos de scaffold (GroupKFold agrupado pelo mesmo scaffold de Bemis-Murcko do split externo), evitando que a mesma família estrutural apareça simultaneamente em treino e validação de um fold.

2.5. Etapa 2 – Aplicação e Quantificação de Incerteza

O modelo com melhor desempenho na Etapa 1 é aplicado ao conjunto proprietário de 5.974 moléculas para gerar um ranking de λ_{max} previsto. Como esse conjunto não possui um solvente rotulado, é adotado como referência constante o solvente mais frequente no Deep4Chem (diclorometano, ClCCl) – decisão que deve ser ajustada conforme o contexto experimental real do laboratório ABC Sim.

Como esse ranking guiará decisões de síntese experimental, foi incorporada quantificação de incerteza, escolhida de acordo com o tipo do modelo vencedor: para os modelos neurais (MLP ou Bi-LSTM), usa-se MC-Dropout [Gal and Ghahramani 2016] – o modelo é mantido em modo de treinamento (dropout ativo) durante a inferência, e múltiplas passadas sobre a mesma molécula produzem uma distribuição de predições cujo desvio-padrão é usado como proxy de incerteza; para o Gradient Boosting, que não possui dropout, é treinado em seu lugar um pequeno ensemble bootstrap de modelos com os mesmos hiperparâmetros, sementes e subamostras (subsample) distintas, cuja dispersão de predições cumpre o mesmo papel. Em ambos os casos, candidatos de alta confiança (baixa variância entre passadas/modelos) são priorizados no ranking final. Também é realizada uma análise de deslocamento de distribuição (domain shift) entre o Deep4Chem e o conjunto proprietário, comparando estatísticas de descritores moleculares-chave

(peso molecular, LogP, TPSA, doadores/aceptores de ligação de hidrogênio, anéis aromáticos, ligações rotacionáveis) por meio do teste de Kolmogorov-Smirnov, para avaliar até que ponto a transferência do modelo é confiável.

3. Resultados

Nota sobre o status dos resultados. Os números desta seção foram obtidos em uma execução de validação do pipeline (QUICK_TEST=True no notebook), sobre uma subamostra de 1.500 registros do Deep4Chem e com um número reduzido de épocas de treino, com o único objetivo de confirmar que o código roda de ponta a ponta sem erros antes da execução completa. Eles não são os resultados finais do projeto – a execução completa (QUICK_TEST=False, dataset inteiro, Google Colab com GPU) ainda precisa ser realizada e deve substituir as tabelas abaixo antes da entrega final. Ainda assim, os resultados preliminares já são informativos e são discutidos como tal.

3.1. Comparação entre modelos (Etapa 1)

A Tabela 1 mostra o desempenho dos três modelos obrigatórios no conjunto de teste (scaffold split), na execução preliminar sobre 1.500 registros (1.216 de treino / 284 de teste, 0 scaffolds em comum entre os conjuntos).

Tabela 1. Comparação de desempenho dos modelos na Etapa 1 (conjunto de teste, scaffold split) – resultado preliminar, subamostra de validação do pipeline.

Modelo	MAE (nm)	RMSE (nm)
Gradient Boosting (descritores RDKit)	44,5	60,5
MLP + fingerprints Morgan	51,1	70,7
Bi-LSTM (SMILES + solvente)	81,5	109,8
D-MPNN (Chemprop, opcional)	—	—

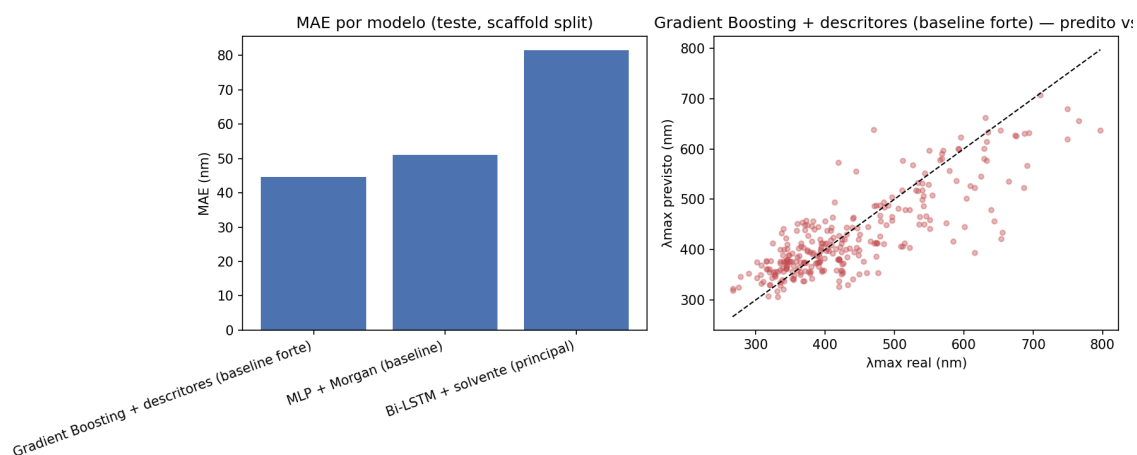


Figura 1. Esquerda: MAE de teste por modelo. Direita: dispersão λ_{max} previsto vs. real para o melhor modelo (Gradient Boosting) – resultado preliminar (subamostra de validação).

Nessa rodada reduzida, o Gradient Boosting superou tanto o MLP quanto a Bi-LSTM. Os descritores RDKit mais importantes para o modelo foram, em ordem: MaxAbsPartialCharge, NumAliphaticHeterocycles, fr_allylic_oxid, SMR_VSA10, BCUT2D_MRLOW, PEOE_VSA8, BertzCT, MinPartialCharge, Chi3n e NumAliphaticRings – coerente com a expectativa química de que cargas parciais e complexidade estrutural/eletrônica estão associadas à posição de λ_{max} . A Bi-LSTM, apesar de ser o modelo principal proposto, teve o pior desempenho nessa execução reduzida; a hipótese mais provável (a ser confirmada na execução completa, ver Seção 4) é que redes neurais treinadas do zero sobre representações char-level exigem mais dados e épocas para convergir do que uma subamostra de 1.216 moléculas de treino permite.

3.2. Etapa 2 – Ranking e incerteza

O modelo vencedor da Etapa 1 nessa rodada preliminar (Gradient Boosting) foi aplicado às 5.974 moléculas do conjunto proprietário, com o solvente de referência constante CClCl (diclorometano) e quantificação de incerteza por ensemble bootstrap (5 modelos). A Tabela 2 resume a distribuição do λ_{max} previsto e da incerteza (desvio-padrão entre modelos do ensemble); a Figura 2 mostra a distribuição do ranking e a relação entre λ_{max} previsto e incerteza.

Tabela 2. Estatísticas descritivas do ranking de λ_{max} previsto para as 5.974 moléculas proprietárias – resultado preliminar.

Estatística	λ_{max} previsto (nm)	Incerteza – desvio padrão (nm)
Média	466,4	21,5
Desvio padrão	53,2	7,4
Mínimo	321,8	2,3
1º quartil	428,6	16,3
Mediana	464,2	21,2
3º quartil	503,2	26,4
Máximo	670,0	51,2

Os candidatos prioritários para síntese são selecionados combinando alto λ_{max} previsto e incerteza abaixo da mediana; entre os 15 candidatos de maior λ_{max} previsto nessas condições, os valores variam entre 600 e 647 nm, com incerteza entre 8,6 e 21,2 nm. O ranking completo, com as colunas de proveniência (anéis/fragmentos de origem), é exportado em resources/ranking_lambda_max_proprietario.csv para uso direto pelo laboratório ABC Sim.

3.3. Deslocamento de distribuição (domain shift)

A Tabela 3 e a Figura 3 comparam a distribuição de sete descritores moleculares-chave entre os cromóforos de treino do Deep4Chem e as moléculas do conjunto proprietário, via teste de Kolmogorov-Smirnov (hipótese nula: mesma distribuição).

O deslocamento de distribuição é acentuado em todos os sete descritores avaliados (KS entre 0,45 e 0,75, todos com $p < 10^{-180}$). As moléculas proprietárias são, em média, muito mais polares (TPSA quase $3\times$ maior) e ricas em doadores/aceptores




Figura 2. Esquerda: distribuição do λ_{max} previsto para o conjunto proprietário. Direita: λ_{max} previsto vs. incerteza, com a mediana da incerteza como referência para a triagem de candidatos de alta confiança – resultado preliminar.

Tabela 3. Deslocamento de distribuição entre o Deep4Chem (treino) e o conjunto proprietário – resultado preliminar, ordenado por estatística KS decrescente. Todos os p -valores $< 10^{-180}$.

Descritor	Média Deep4Chem	Média proprietário	KS
NumHAcceptors	3,45	8,81	0,747
TPSA	50,35	148,06	0,745
NumHDonors	0,49	3,13	0,737
NumAromaticRings	4,21	0,92	0,714
MolLogP	6,51	1,39	0,618
NumRotatableBonds	5,10	8,53	0,531
MolWt	456,15	524,57	0,448

de ligação de hidrogênio, porém possuem menos anéis aromáticos e menor LogP que os cromóforos do Deep4Chem. Como o Deep4Chem é majoritariamente composto por corantes e cromóforos aromáticos conjugados, e o conjunto proprietário parece ocupar uma região mais polar e menos aromática do espaço químico, essa é uma evidência direta de que a transferência do modelo para o conjunto proprietário deve ser tratada com cautela, conforme discutido na Seção 4.

4. Lições Aprendidas

- O que funcionou. O scaffold split foi implementado e validado corretamente (interseção de scaffolds entre treino e teste igual a zero em todas as execuções). A busca de hiperparâmetros por validação cruzada em grupos de scaffold (GroupKFold) funcionou de forma estável para os três modelos e é reaproveitada, sem alteração de código, entre a execução de validação e a execução completa.
- Dificuldades de parsing e como foram resolvidas. Cerca de metade dos SMILES do conjunto proprietário usa aromaticidade explícita com o símbolo : entre átomos não declarados como aromáticos, o que o parser padrão do RD-Kit rejeita por falha de kekulização. A solução – reparsear com `sanitize=False`




Figura 3. Distribuições sobrepostas de descritores-chave: Deep4Chem (treino) vs. conjunto proprietário – resultado preliminar.

e pular apenas a etapa SANITIZE_KEKULIZE – elevou a taxa de sucesso de $\approx 49\%$ para 100% e foi documentada como decisão de design explícita no notebook, não como um contorno silencioso.

- Um bug sutil de overflow numérico. Ao calcular o conjunto completo de ≈ 217 descritores RDKit por molécula para o Gradient Boosting, o descritor Ipc (índice de conteúdo de informação) assume valores absurdamente grandes para moléculas maiores, causando overflow silencioso ao converter para float32 e quebrando o treino do GBM com um ValueError de valores não finitos. A correção foi limitar (clip) os descritores a um intervalo numérico seguro antes da conversão de tipo – um lembrete de que descritores químicos podem ter escalas muito heterogêneas e não devem ser usados sem normalização/tratamento de outliers.
- Decisões de design que valeriam revisão. A escolha de um solvente de referência constante (o mais frequente no Deep4Chem, diclorometano) para a Etapa 2, dado que o conjunto proprietário não tem solvente rotulado, é uma simplificação que deveria ser validada com o laboratório ABC Sim – o solvente efetivamente usado na caracterização das amostras pode ser diferente e influenciar materialmente o λ_{max} previsto, dado o efeito solvatocrômico.
- O deslocamento de distribuição é o maior risco do projeto. A análise da Seção 3.3 mostrou que o conjunto proprietário ocupa uma região do espaço químico sistematicamente diferente do Deep4Chem (mais polar, menos aromática). Isso significa que, mesmo que o melhor modelo tenha bom desempenho no teste do Deep4Chem, sua confiabilidade ao ser aplicado ao conjunto proprietário não pode ser assumida sem essa análise – e reforça a importância da quantificação de incerteza (Seção 2.5) para não tratar todas as previsões da Etapa 2 com o mesmo grau de confiança.
- O que será feito diferente / próximos passos. (i) Executar o notebook completo com QUICK_TEST=False no Google Colab (GPU) sobre o Deep4Chem inteiro e substituir as Tabelas 1–3 pelos resultados finais – a expectativa é que a Bi-LSTM, que exige mais dados para convergir, melhore

de posição relativa ao GBM com o dataset completo; (ii) treinar a extensão opcional D-MPNN (Chemprop) como comparação de estado da arte, caso haja tempo disponível; (iii) comparar quantitativamente o scaffold split com um split aleatório de controle, para reportar o quanto o scaffold split é de fato mais conservador.

5. Reprodutibilidade

O código completo do projeto (pré-processamento, treinamento dos modelos, avaliação e aplicação na Etapa 2) está disponível em: <https://github.com/crhisangela/ai-ronaldo>.

O repositório inclui o notebook `sandbox/sandbox.ipynb`, usado para todos os experimentos, com um flag `QUICK_TEST` que alterna entre uma execução reduzida de validação do pipeline (usada para gerar os resultados preliminares desta seção) e a execução completa sobre o Deep4Chem inteiro. O Deep4Chem é baixado automaticamente do Figshare na primeira execução e mantido em cache local (`resources/deep4chem_raw/`); o conjunto proprietário é lido de `resources/banco_smiles_aromatizados.parquet`.

Referências

- Bemis, G. W. and Murcko, M. A. (1996). The properties of known drugs. 1. molecular frameworks. *Journal of Medicinal Chemistry*, 39(15):2887–2893.
- Friedman, J. H. (2001). Greedy function approximation: A gradient boosting machine. *The Annals of Statistics*, 29(5):1189–1232.
- Gal, Y. and Ghahramani, Z. (2016). Dropout as a bayesian approximation: Representing model uncertainty in deep learning. In *Proceedings of the 33rd International Conference on Machine Learning (ICML)*, pages 1050–1059.
- Joung, J. F., Han, M., Jeong, J., and Park, S. (2020). Experimental database of optical properties of organic compounds. *Scientific Data*, 7:295.
- RDKit (2024). Rdkit: Open-source cheminformatics. <https://www.rdkit.org>.
- Rogers, D. and Hahn, M. (2010). Extended-connectivity fingerprints. *Journal of Chemical Information and Modeling*, 50(5):742–754.
- Schuster, M. and Paliwal, K. K. (1997). Bidirectional recurrent neural networks. *IEEE Transactions on Signal Processing*, 45(11):2673–2681.
- Yang, K., Swanson, K., Jin, W., et al. (2019). Analyzing learned molecular representations for property prediction. *Journal of Chemical Information and Modeling*, 59:3370–3388.